

PROPOSTA TÉCNICA

Pipeline de IA para Extração e Estruturação Automática de Taxas de Intercâmbio — Visa & Mastercard

Documento de Entrega — Desafio Técnico Bolsista Doutor Bandeiras
Versão 1.0 | Junho de 2026

Sumário

1	Análise Exploratória dos Documentos	2
1.1	Estrutura Geral dos Manuais	2
1.2	Padrões Tarifários e Regras de Segmentação	2
1.3	Desafios na Leitura dos PDFs	3
2	Proposta de Pipeline para Extração e Estruturação	5
2.1	Visão Geral do Fluxo	5
2.2	Estágio 1 — Ingestão do PDF	5
2.3	Estágio 2 — Chunking Estrutural	6
2.4	Estágio 3 — Embedding e Indexação	7
2.5	Estágio 4 — Extração Semântica via LLM/Agente	8
2.6	Estágio 5 — Validação e Reconciliação	8
3	Abordagem Técnica e Modelagem de Banco de Dados	9
3.1	Arquitetura Híbrida: Relacional + Vetorial	9
3.2	Esquema Relacional (DDL Simplificado)	9
3.2.1	Tabela <code>bandeiras</code>	9
3.2.2	Tabela <code>regras_intercambio</code> (Tabela Central)	10
3.3	Consultas Analíticas Ilustrativas	10
4	Visualizações Estratégicas e Dashboards	11
4.1	Visão Comparativa 1 — Visa vs. Mastercard em E-Commerce	11
4.2	Visão Comparativa 2 — Detalhamento por MCC e Filtros Dinâmicos	11
5	Recomendações Técnicas para Evolução do Agente de IA	11
5.1	Escalabilidade e Processamento em Escala	11
5.2	Monitoramento de Concept Drift	12
5.3	Mecanismos de Atenção, Re-Ranking e Segurança	12

1 Análise Exploratória dos Documentos

1.1 Estrutura Geral dos Manuais

Os manuais de taxas de intercâmbio da Visa e Mastercard são documentos técnicos publicados periodicamente em formato PDF. Para a montagem desta proposta de pipeline, foram considerados dois documentos como base:

- **Visa USA Interchange Reimbursement Fees** — versão de 18 de abril de 2026.
- **Mastercard U.S. Region Interchange Programs and Rates 2025–2026** — vigente a partir de 11 de abril de 2025.

Ambos os documentos compartilham uma arquitetura tabular densa, porém com diferenças significativas de nomenclatura, hierarquia e segmentação, conforme detalhado na Tabela 1.

Tabela 1: Comparativo de Características dos Manuais Visa e Mastercard

Característica	Visa	Mastercard
Nº médio de tabelas	~25–35	~20–30
Hierarquia de produto	Infinite / Signature / Traditional / Check / Prepaid	World Elite / World High Value / World / Enhanced Value / Core
Dimensão de segmentação	Tipo de cartão × Modalidade (CP/CNP) × MCC	Tipo de cartão × Programa (Merit I, III, Supermarket...) × MCC
Formato de taxa	$X.XX\% + \$Y.YY$ com caps opcionais	$X.XX\% + \$Y.YY$ com caps opcionais
Tiers volumétricos	Sim (Supermarket Tiers 0–III)	Sim (Merit III Tiers 1–3, Supermarket Tiers 1–3)
Notas de rodapé críticas	Sim (~3–8 por tabela)	Sim (~4–6 por tabela)

1.2 Padrões Tarifários e Regras de Segmentação

A segmentação dos intercâmbios obedece a múltiplas dimensões simultaneamente. Compreendê-las é fundamental para qualquer pipeline de extração:

a) Tipo de cartão (Card Product)

Visa e Mastercard diferenciam claramente cartões de crédito, débito (regulado vs. isento) e pré-pago (regulado vs. isento). A regulação referenciada é o *Durbin Amendment* (Regulation II), que limita as taxas de débito regulado em $0.05\% + \$0.21$.

b) Presença física vs. remoto (Card Present / Card Not Present)

Todas as tabelas distinguem transações com cartão fisicamente presente (CP) das não-presenciais (CNP), incluindo e-commerce. As taxas CNP são invariavelmente superiores, refletindo maior risco de fraude.

c) Merchant Category Code (MCC)

O MCC é o vetor de segmentação mais granular. Exemplos de categorias com tratamento especial:

- **Supermarket** (MCC 5411): Visa pratica taxas diferenciadas por tiers de volume (Tier 0 a III), com variação de 1.18% + \$0.05 a 2.00% + \$0.07 para crédito. Mastercard segmenta similarmente com Base + Tier 1/2/3.
- **Petroleum/AFD** (*Automated Fuel Dispenser* — MCCs 5541, 5542): ambas as bandeiras aplicam cap de \$0.95, independente do percentual calculado.
- **Utilities** (MCCs 4900–4999): Mastercard aplica taxa fixa de \$0.75 por transação, sem componente percentual.
- **Government / Public Sector**: taxas reduzidas com caps explícitos (\$2.00 na Visa; segmento *Public Sector* na Mastercard com 1.55% + \$0.10).
- **Charities**: ambas praticam taxas preferenciais (2.00% + \$0.10 na Mastercard, independente do tier de produto).
- **Gaming MCCs** (Mastercard: 7800, 7801, 7802, 7994, 7995): taxa de 0.00% + \$0.10, refletindo tratamento de "*payment transaction*".

d) Modalidades especiais de transação

Conforme resumido na Tabela 2.

Tabela 2: Modalidades Especiais de Transação e Padrões de Taxas

Modalidade	Visa	Mastercard
Small Ticket ($\leq \$10 - \15)	Taxa específica, ex: 1.55%+\$0.04 débito	Taxa específica, ex: 1.65%+\$0.02 crédito CP
Contactless	Subsumir nas taxas CP padrão; sem linha separada	Idem
Pré-pago isento	Tabela B dedicada (1.15%+\$0.15 base)	Coluna Prepaid Rate na tabela Debit/Prepaid
Key-Entered / CNP sem aut.	Taxas majoradas (1.65% + \$0.15 débito)	1.95% + \$0.10 crédito
Full UCAF (e-commerce aut.)	Taxas preferentes vs. Standard CNP	1.95% + \$0.10 (crédito Core)
Debt Repayment	Taxa com caps distintos (\$2.00 e \$0.65)	N/A como linha separada

1.3 Desafios na Leitura dos PDFs

Desafio 1 — Tabelas multi-header hierárquicas.

As tabelas da Visa possuem até três níveis de cabeçalho: (i) seção do documento (ex: “Consumer Credit”), (ii) modalidade (Card Present / Card Not Present), e (iii) produto (Visa Infinite / Signature...). O parser deve resolver essa hierarquia para associar cada célula a seus eixos corretos.

Desafio 2 — Notas de rodapé como modificadores de regra.

Asteriscos, superescritos numéricos e letras referenciam condições que alteram o valor principal. Por exemplo, na Visa: * indica adicional de \$0.01 para issuers com certificação de prevenção de fraude; 1 restringe a taxa de Small Ticket a transações na rede 002. Ignorar estas notas produz dados incorretos para casos de uso reais.

Desafio 3 — Caps e valores mínimos embutidos em células.

A formatação 1.90%+\$0.00 (0.95 max) da Mastercard Petroleum e 0.80%+\$0.15 (\$0.15 min / \$2.00 max) da Visa exige parsing de estrutura interna da célula, não apenas extração de texto.

Desafio 4 — Tiers volumétricos com critérios de qualificação em tabelas auxiliares.

Os critérios de elegibilidade aos tiers (ex: Mastercard Merit III Tier 1 exige volume mínimo anual de USD 1,80 bilhão) aparecem em tabelas separadas dos valores das taxas. O pipeline precisa juntar estas entidades.

Desafio 5 — Variação de layout entre versões.

As bandeiras alteram layout, nomenclatura e ordem das tabelas entre publicações semestrais. Um pipeline robusto não pode depender de posições fixas de células.

Desafio 6 — Conteúdo misto (texto narrativo + tabelas).

Parágrafos introdutórios e notas legais intercalam-se com as tabelas. O pipeline deve distinguir blocos de prosa dos blocos tabulares.

2 Proposta de Pipeline para Extração e Estruturação

A arquitetura proposta é inspirada no framework **RAG (Retrieval-Augmented Generation)** e organizada em cinco estágios principais: **Ingestion** → **Chunking** → **Embedding** → **Indexing** → **Retrieval** + **LLM**.

2.1 Visão Geral do Fluxo




Figura 1: Diagrama de Blocos da Arquitetura do Pipeline

2.2 Estágio 1 — Ingestão do PDF

Objetivo: Converter o PDF em representações intermediárias que preservem a estrutura (tabelas, hierarquia de cabeçalhos, notas de rodapé).

Processo detalhado:

1. Abertura do PDF via `pdfplumber`; iteração por página.
2. Detecção de blocos tabulares via bounding boxes.
3. Extração de texto narrativo separadamente (introduções, notas legais).
4. Aplicação de OCR seletivo em páginas onde a extração digital falha.

Tabela 3: Ferramentas Recomendadas para Ingestão

Ferramenta	Papel	Justificativa
pdfplumber	Extração de tabelas com bounding boxes	Preserva posição de células; lida com tabelas sem bordas explícitas
pymupdf (fitz)	Extração de texto bruto e blocos	Alta performance; suporte a metadados de página
unstructured	Classificação de elementos	Reduz trabalho de heurística manual
pytesseract	OCR de fallback	Suporte para páginas escaneadas ou artefatos
camelot	Extração alternativa de tabelas	Robusto para formatos tipo lattice/stream

5. Saída: lista de objetos PageBlock com tipo (table | text | footnote), conteúdo bruto e coordenadas.




Figura 2: Representação Conceitual do Comparativo de Processamento do Pipeline

2.3 Estágio 2 — Chunking Estrutural

Objetivo: Dividir o conteúdo em unidades semânticas coerentes, preservando contexto hierárquico. Esta etapa diverge do chunking tradicional por tokens porque o domínio exige **chunking orientado a entidade de regra**.

Estratégia de chunking em três camadas:

→ **Nível 1:** Seção do documento

→ **Nível 2:** Tabela (com todos os seus cabeçalhos resolvidos)

→ **Nível 3:** Linha de regra (combinação MCC × Produto × Modalidade × Taxa)

Cada **chunk de Nível 3** é a unidade mínima indexável e deve conter contextos herdados dos níveis superiores, valores de taxa, referências resolvidas a notas de rodapé e metadados estruturais (`page_number`, `table_id`, `version_date`).

```
1 def resolve_headers(raw_table: list[list[str]]) -> list[dict]:
2     header_rows = detect_header_rows(raw_table)
3     merged_header = merge_hierarchical_headers(header_rows)
4     data_rows = raw_table[len(header_rows):]
5     return [
6         {col: row[i] for i, col in enumerate(merged_header)}
7         for row in data_rows
8     ]
```

Listing 1: Pseudocódigo de resolução de multi-header

Resolução de notas de rodapé: As notas são extraídas como entidades separadas e vinculadas aos chunks por referência de símbolo (*, 1, a). Um LLM local via Ollama (llama3.2 ou qwen2.5:3b) é usado para parafrasear a nota em linguagem estruturada.

2.4 Estágio 3 — Embedding e Indexação

Objetivo: Converter chunks em vetores densos para busca semântica pelo Agente de Consulta. Recomendam-se os modelos `text-embedding-3-large` (OpenAI) ou `BAAI/bge-m3`.

Tabela 4: Estratégias de Indexação de Vetores

Estratégia	Quando usar	Configuração
HNSW	Operação interativa (Q&A em tempo real)	Latência < 10ms; dataset < 10M vetores
IVF	Batch analytics, re-processamento	Corpus estável; controle de memória de hardware

Vector Store recomendado: **Qdrant** ou **Weaviate** (suporte nativo a payload filtering e hybrid search).

```
1 {
2     "bandeira": "visa",
3     "tipo_cartao": "credit",
4     "produto": "visa_signature",
5     "modalidade": "card_not_present",
6     "segmento": "supermarket",
7     "mcc_range": "5411",
8     "version_date": "2026-04-18",
9     "regulated": false
10 }
```

2.5 Estágio 4 — Extração Semântica via LLM/Agente

Objetivo: Usar um LLM como leitor inteligente para resolver ambiguidades e converter tabelas brutas em registros JSON normalizados.

AGENTE DE EXTRAÇÃO (LLM)

```
Tool 1: parse_table_chunk(raw_html_table)
Tool 2: resolve_footnote(symbol, footnote_text)
Tool 3: validate_rate_format(rate_string)
Tool 4: classify_mcc(description)
Tool 5: detect_cap_or_floor(cell_text)
```

Figura 3: Arquitetura e Ferramentas do Agente de Extração

Para a extração de tabelas financeiras densas, recomenda-se o uso de modelos estruturados nativos de alta capacidade como `llama3.1:70b` ou `qwen2.5:72b` para evitar alucinações.

2.6 Estágio 5 — Validação e Reconciliação

1. **Validação de formato:** Garantir que `rate_pct` $\in [0, 5]$, `rate_fixed` $\in [0, 2]$ e caps sejam positivos.
2. **Validação de completude:** Disparar alertas caso campos obrigatórios estejam ausentes.
3. **Validação cruzada:** Verificar consistência histórica de programas equivalentes.
4. **Validação por versão:** Identificar variações bruscas ($> 0.5pp$) comparativamente à versão anterior.

Framework: Uso do `Great Expectations` (Python) com alertas via webhook.

3 Abordagem Técnica e Modelagem de Banco de Dados

3.1 Arquitetura Híbrida: Relacional + Vetorial

Propõe-se o uso do **PostgreSQL** (com extensão **TimescaleDB**) para queries determinísticas e simulações analíticas, operando em paralelo ao **Qdrant** para recuperação semântica do Agente RAG.




Figura 4: Arquitetura Híbrida: Banco Relacional (PostgreSQL) e Vetorial (Qdrant)

3.2 Esquema Relacional (DDL Simplificado)

Abaixo são apresentadas as estruturas das tabelas principais da camada relacional.

3.2.1 Tabela bandeiras

Campo	Tipo	Descrição
id	UUID PK	Identificador único da bandeira
nome	VARCHAR(50)	Ex: “visa”, “mastercard”
documento_origem	VARCHAR(255)	Caminho ou hash do PDF fonte
versao_data	DATE	Data de vigência das taxas

3.2.2 Tabela regras_intercambio (Tabela Central)

Campo	Tipo	Descrição
id	UUID PK	Identificador único da regra
bandeira_id	UUID FK	Relacionamento com tabela bandeiras
fee_program	VARCHAR(200)	Nome original do programa (ex: “CPS/Retail”)
modalidade	ENUM	card_present ou card_not_present
rate_pct	DECIMAL(5,4)	Percentual da taxa (ex: 0.0165 para 1.65%)
rate_fixed_usd	DECIMAL(6,4)	Componente fixo em dólar (ex: 0.15)
cap_usd	DECIMAL(6,4)	Valor de teto máximo (NULL se inexistente)
floor_usd	DECIMAL(6,4)	Valor de piso mínimo (NULL se inexistente)
vigencia_inicio	DATE	Data de início da vigência
vigencia_fim	DATE	Data de término (NULL se atual)

3.3 Consultas Analíticas Ilustrativas

```
1  -- 1. Taxa média ponderada para e-commerce, crédito, por bandeira
2  SELECT
3      b.nome AS bandeira,
4      AVG(r.rate_pct * 100) AS taxa_pct_media,
5      AVG(r.rate_fixed_usd) AS fixo_medio_usd
6  FROM regras_intercambio r
7  JOIN bandeiras b ON r.bandeira_id = b.id
8  JOIN tipos_cartao tc ON r.tipo_cartao_id = tc.id
9  WHERE r.modalidade = 'card_not_present'
10     AND tc.categoria = 'credit'
11     AND r.vigencia_fim IS NULL
12  GROUP BY b.nome;
13
14  -- 2. Identificar programas com cap ativo por segmento
15  SELECT fee_program, rate_pct * 100 AS pct, rate_fixed_usd, cap_usd
16  FROM regras_intercambio
17  WHERE cap_usd IS NOT NULL
18  ORDER BY segmento_id, bandeira_id;
```

Listing 3: Queries de Agregação e Auditoria Analítica

4 Visualizações Estratégicas e Dashboards

Os dados estruturados alimentam visualizações integradas via **Metabase** conectado ao PostgreSQL.

4.1 Visão Comparativa 1 — Visa vs. Mastercard em E-Commerce

Consiste em um **Heatmap de taxa efetiva** calculada sobre um ticket médio de referência de \$50 ($Rate\% + \frac{Fixed}{Ticket}$).

Tabela 5: Exemplo de Matriz de Comparabilidade de Taxas Efetivas (CNP Crédito)

Segmento	Visa Infinite CNP	MC World Elite CNP	Δ (pp)
Supermarket	2.00% + \$0.07	2.10% + \$0.10	$\sim +0.13$
Restaurant	—	2.00% + \$0.10	—
Petroleum (cap \$0.95)	1.80% + \$0.07	2.00% + \$0.00	Variável
Utilities	$\sim 1.65\% + \$0.15$	\$0.75 fixo	Variável
Government	0.65% + \$0.15 (cap \$2.00)	1.55% + \$0.10	Variável

4.2 Visão Comparativa 2 — Detalhamento por MCC e Filtros Dinâmicos

Gráficos de barras agrupados no dashboard permitem a filtragem rápida por tipo de cartão, modalidade (CP/CNP) e tiers de produtos. KPIs centrais destacam volumetria de programas modificados e dão acesso a um **Simulador de Custo Transacional** parametrizável.

5 Recomendações Técnicas para Evolução do Agente de IA

5.1 Escalabilidade e Processamento em Escala

- **Apache Airflow:** Utilizado para automação e orquestração de DAGs de ingestão baseadas no hash dos arquivos dos manuais.
- **Polars:** Substituição do Pandas por manipulação via Polars/PyArrow para otimização de memória em processamento batch.

```
1 import polars as pl
2
3 df = pl.read_ndjson("extracted_rules.ndjson")
4 df_normalized = (
5     df
6     .with_columns([
7         (pl.col("rate_pct") / 100).alias("rate_pct_decimal"),
8         pl.col("cap_usd").fill_null(float("inf")).alias("
9     cap_usd_safe"),
10    ])
11    .filter(pl.col("rate_pct") > 0)
12    .sort(["bandeira", "tipo_cartao", "fee_program"])
```

5.2 Monitoramento de Concept Drift

Para prevenir falhas operacionais decorrentes de alterações semestrais nos layouts dos PDFs, recomenda-se a implementação de um **Hash estrutural de tabelas** (identificação de quebras de esquemas) associado à análise de **Embedding Drift** via métrica de distância de cosseno aplicável aos vetores gerados das novas tabelas.

5.3 Mecanismos de Atenção, Re-Ranking e Segurança

- **Cross-Encoder Re-Ranking:** Aplicação do modelo `cross-encoder/ms-marco-MiniLM-L-6-v2` pós-recuperação vetorial para mitigar falsos positivos semânticos.
- **Filtros Temporais Restritivos:** Inclusão mandatória de metadados de vigência (`vigencia_fim IS NULL`) nas queries de busca do pipeline RAG.
- **Segurança e Governança:** Controle de acessos via *Metadata Filtering* (estratégia *Shared Index*) garantindo isolamento corporativo (*multi-tenancy*) e trilhas completas de auditoria de dados.

Dr. Ademir Batista dos Santos Neto
Cientista de Dados Sênior
Junho de 2026